

Variable Cepheid classification from unprocessed light curves

Maximiliano Garavito Chtefan



Justificación

Las cefeidas clásicas [también conocidas como estrellas delta Cepheida, cefeidas tipo I o cefeidas de población I] se encuentran entre las estrellas variables más famosas e importantes.

Son estrellas relativamente jóvenes, masivas, de pulsaciones radiales con relaciones bien definidas entre la magnitud absoluta y el período, lo que las convierte en importantes indicadores de distancias intra y extragalácticas.




Justificación

Sin embargo, clasificar estas estrellas puede ser un problema complejo, que requiere de mucha interacción con expertos.


Esto es así debido a que no es sencillo diferenciar cefeidas variables de otros tipos de estrellas como las RR Lyrae variable. Además, es común que hayan curvas de luz de muy pocas noches de observación en periodos muy largos de tiempo.

Esto se traduce en que cada curva de luz deba ser individualmente analizada con heurísticas de carácter estadístico, para así conocer si es una posible candidata a cefeida variable y posteriormente simular los periodos más probables; finalmente determinando si es cefeida variable o no. Lo que requiere de un trabajo extenso y dispendioso por parte de astrónomos.








1_760, KCC, P=8.26 d




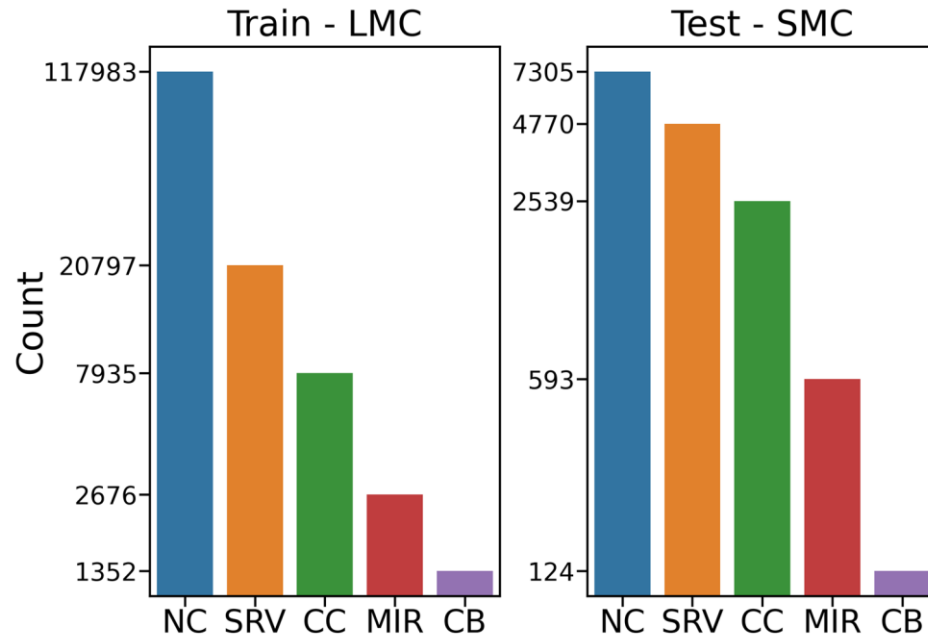
1_486, EB, P=0.97 d



Datasets

OGLE Project: estudio del cielo a gran escala realizado desde 1992 por astrónomos asociados con el Observatorio Astronómico de la Universidad de Varsovia con el telescopio Observatorio Las Campanas, Chile. El Catálogo OGLE de Estrellas Variables consta de más de 400.000 objetos y ahora es el mayor conjunto de estrellas variables del mundo.





LMC: Large magellanic cloud
SMC: Small magellanic cloud

MIR: Mira- red giant
CC: Cepheid
NC: No contact
CB: Contact binary
SRV: Semiregular variable


Desbalance del dataset del proyecto OGLE por tipos de
estrellas variables



Subsampling and data augmentation

```
def subsample(serie,numbers,dist,mask_value):
    '''Function to decompose a time serie into multiple randomly subsampled time series with number of
    numbers with distribution of number of points given by dist, the subsampled time series are padded
    the return is a numpy array of shape (n,max_number,channels) where n is the number of generated sub
    max_number is the greatest value of numbers and channels is the features of the serie'''
    max_steps=np.max(numbers)
    l=len(serie)
    if l<=max_steps:
        arr=np.ones((1,max_steps,3))*mask_value
        s=np.shape(serie)
        arr[0,:s[0]]=serie
        return arr
    else:
        n=np.random.choice(numbers,replace=False, p=dist)
        sel=np.sort(np.random.choice(l,n,replace=False))
        serie_trunc=serie[sel]
        s=np.shape(serie_trunc)
        arr=np.ones((1,max_steps,3))*mask_value
        arr[0,:s[0]]=serie_trunc
        bool_sel=np.ones(l).astype(bool)
        bool_sel[sel]=False
        serie=serie[bool_sel]
        l=len(serie)
        while l>=max_steps:
            n=np.random.choice(numbers,replace=False, p=dist)
            sel=np.sort(np.random.choice(l,n,replace=False))
            serie_trunc=serie[sel]
            s=np.shape(serie_trunc)
            t=np.ones((1,max_steps,3))*mask_value
            t[0,:s[0]]=serie_trunc
            arr=np.concatenate((arr,t))
            bool_sel=np.ones(l).astype(bool)
            bool_sel[sel]=False
            serie=serie[bool_sel]
            l=len(serie)
        if l>=np.min(numbers):
            s=np.shape(serie)
            t=np.ones((1,max_steps,3))*mask_value
            t[0,:s[0]]=serie
            arr=np.concatenate((arr,t))
        return arr
```





Datos remuestreados para que coincidan con la
colección Uniandes de Estrellas Variables
(El telescopio MPG / ESO 2.2m)



Custom Layer

```
class lstm_bottleneck(tfkl.Layer):
    def __init__(self, lstm_units, time_steps, **kwargs):
        self.lstm_units = lstm_units
        self.time_steps = time_steps
        self.lstm_layer = tfkl.Bidirectional(tfkl.LSTM(lstm_units, return_sequences=False))
        self.repeat_layer = tfkl.RepeatVector(time_steps)
        super(lstm_bottleneck, self).__init__(**kwargs)

    def call(self, inputs):
        # just call the two initialized layers
        return self.repeat_layer(self.lstm_layer(inputs))

    def compute_mask(self, inputs, mask=None):
        # return the input_mask directly
        return mask
```





Arquitecturas implementadas

Layer (type)	Output Shape	Param #
masking_1 (Masking)	(None, 32, 3)	0
bidirectional_4 (Bidirection	(None, 32, 64)	9216
lstm_bottleneck_1 (lstm_bott	(None, 32, 14)	4032
Total params: 13,248		
Trainable params: 13,248		
Non-trainable params: 0		

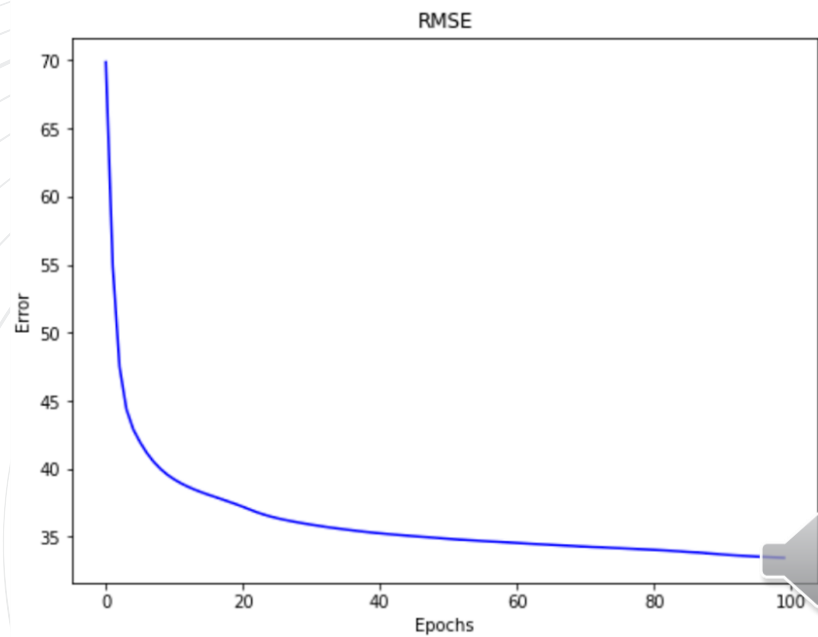

Layer (type)	Output Shape	Param #
bidirectional_6 (Bidirection	(None, 32, 64)	12032
bidirectional_7 (Bidirection	(None, 32, 6)	1632
dense_1 (Dense)	(None, 32, 3)	21
Total params: 13,685		
Trainable params: 13,685		
Non-trainable params: 0		



Resultados



Resultados



→ Funciones de validación

```
def mask(arr,mask_value=-8):  
    sel=np.diff(arr,axis=0)  
    sel=np.sum(sel,axis=1)!=0.  
    sel=np.concatenate((sel,[False]))  
    return sum(sel)
```

```
def masked_mse(prediction,real_vals,mask,mask_value=-8):  
    dif=prediction[:mask]-real_vals[:mask]  
    mse = (np.square(dif)).mean(axis=None)  
    return mse
```



MSE por clase

Succes!

Mean MSE for Cep data is: 5819.561664891817
Max MSE for Cep data is: 190481.8768829917
Min MSE for Cep data is: 23.640436702061876

Mean MSE for Rrlyr data is: 11966346.737544492
Max MSE for Rrlyr data is: 22383903.090269934
Min MSE for Rrlyr data is: 9820725.792896278

Mean MSE for Acep data is: 10483469.925480977
Max MSE for Acep data is: 11124888.48133775
Min MSE for Acep data is: 9914071.185982602

Mean MSE for T2CEP data is: 10483469.925480977
Max MSE for T2CEP data is: 11124888.48133775
Min MSE for T2CEP data is: 9914071.185982602

Mean MSE for Ecl data is: 10483469.925480977
Max MSE for Ecl data is: 11124888.48133775
Min MSE for Ecl data is: 9914071.185982602

